Informe

Integrantes

- Cristobal Albornoz
- Sebastián Barría
- Benjamín Peña

Respuestas incisos:

b) Implementación de bootstrapping

Se creó un archivo de utils compartidas `common.py` y un archivo para cada una de las implementaciones de bootstrapping:

common.py

- El ajuste lineal se resuelve por factorización directa en vez de invertir matrices explícitamente.
- Cada resample bootstrap se construye usando una identidad algebraica que evita reconstruir el dataset completo por repetición: se trabaja con pesos y se descartan las filas no sorteadas, reduciendo el volumen de cómputo por tarea.

bs_auto.py Delega el bootstrapping y el paralelismo por completo a una librería externa. No aplica el descarte de filas no sorteadas ni la construcción optimizada del resample, por lo que hace más trabajo por tarea que las otras dos versiones.

bs_sklearn.py Aplica la construcción optimizada del resample (pesos + descarte de filas), pero el ajuste final usa un método numérico más costoso propio de la librería, que es el cuello de botella de esta versión.

bs_numpy.py La versión que más se pudo optimizar: combina paralelismo explícito, construcción eficiente del resample y resolución directa del sistema de ecuaciones normales, minimizando tanto el trabajo por tarea como la sobrecarga de cómputo. Es la más rápida en tiempo absoluto, pero por lo mismo la más sensible a la sobrecarga fija de paralelización (cada tarea es tan liviana que el costo de repartirla entre procesos pesa proporcionalmente más).

c) Correctitud y reproducibilidad

i) Respecto a los IC, a nivel general, se usa una función *ci_percentil()* para poder calcularlos de igual manera al final de la ejecución de cada una de las variantes del algoritmo, entregando los *betas* calculados y el *alpha=0.05*, resultando en descartar 1 valor por lado (descarta el 2.5% superior o inferior,

equivalente al multiplicar por B=48 –> 1) y lograr un nivel de confianza de 95% aproximadamente. Para verificar esto, se utiliza la función *cobertura()*, para poder calcular la fracción de los coeficientes verdaderos (BETA_STAR) que quedan dentro del IC, la cual se espera que rondee ese 95% en los resultados empíricos

En cuanto a los resultados obtenidos, al revisar el reporte obtenido en *tiempos_XXXX.csv* con XXXX = computador en el que fueron ejecutados los algoritmos, se puede apreciar que los IC tienden a tener características idénticas (ancho del IC promedio, cobertura de BETA_STAR y error relativo de BETA_STAR) para las variantes *sklearn* y *numpy*, y ligeramente distintas para las de la versión *auto* (tiene ligeramente peor cobertura, error relativo y es menos ancho que las otras 2)

Los resultados para cada una de las métricas se adjuntan a continuación:

Métrica	PC-1 (sebas)	PC-2 (kintsugi)	PC-3 (aurora-ferrum)
Ancho	0.024227 (+)	0.011812	0.011812
Cobertura	88,5% (-)	~95%	~95%
Error relativo	0.00220527 (+)	0.00042929	0.00042929

ii) En cuanto a equivalencia, tanto *bs_numpy* como *bs_sklearn* usan `common.child.seeds(B)` (que usa SeedSequence) y `common.bootstrap_weights(rng, N)` bajo la misma secuencia de semillas generados por ella, lo que significa que ambas versionas sortean los mismos N índices para el resample *b*, por ende armando los mismos Xˆ(b) e yˆ(b) ponderado, siendo la única diferencia entre ambas el algoritmo usado para resolver el álgebra lineal del problema: - bs_numpy: resuelve mediante ecuaciones normales con `np.linalg.solve`, que hace uso de factorización LU en el producto de X con su transpuesta - bs_sklearn: resuelve mediante `LinearRegression`, que se basa en SVD (Descomposición de Valores Singulares) Como ambos métodos resulelven el mismo sistema, las diferencias entre sus resultades probablemente se deban a errores de redondeo de puntos flotantes, lo cuál tiene ordenes de magnitud muy bajos (1*10ˆ{10} o {12} aprox), lo que se traduce en resultados casi idénticos, como se puede ver en las métricas antes mencionadas, donde para ambos computadores dan = valores.

Por otro lado, *bs_auto* es comparable pero no tan idéntido, de ahí la ligera diferencia entre valores vistos previamente, pues utiliza `BaggingRegressor`el cual hace su propio muestreo bootstrap interno con su propio generador de índices distntos al SeedSequence utilizado por los otros 2. Así, aunque se esté usando la misma semilla, al tener un mecanismo de generación de números aleatorios distinto al `common.child.seeds(B)`, los índices que termina sorteando no coinciden resample a resample con los de *bs_numpy* y *bd_sklearn* - Aquí cabe mencionar que la diferencia radica principalmente en ese muestreo distintos del

conjunto de B coeficientes, pero el mecanismo de bootstrap se mantiene el los 3, por lo que siempre es comparable - Otro aspecto a considerar, aunque del lado computacional, no de resultados, es que *bs_auto* no descarta la fila de peso 0 a diferencia de la implementación en `common.weighted_design`, lo que si las descarta, lo que lo hace más lento como se puede ver en los resultados de los .csv

iii) Para que los resultados sean reproducibles se necesita: - **= semilla en la generación de datos**: Por ello en `gen_data.py`se usa una semilla fija al momento de ejecutar `np.random.default_rng(seed)` al crear los datos sintéticos aleatorios, lo que logra que X y BETA_STAR sean ideńtidos entre ejecuciones y computadores.

NOTA: Además, se guardan los arreglos en un *.npy* para que las 3 variantes de bootstrapping puedan usar los mismos datos y puedan mediante *mmap mode="r"* poder abrirlos sin duplicar la memoria entre procesos. Esto es lo que queda en la carpeta **/data** en forma de `beta_star.npy, X.npy, y.npy`

- **semillas independientes por resample y desacopladas de p**: Como `default_rng(seed + b)`no da garantías de independencias entre streams, pudiendo haber colisiones, si se usara podría hacer que el resultado de las operaciones dependa del orden de ejecución y por ende de *p*. Por ello se plantea usar `p.random.SeedSequence().spawn(B)` en `common.child_seeds`, para generar B streams estadísticamente independientes (lo garantiza al alejarlos mucho mediante el uso de hashing criptográfico) y generar streams que provoquen que el mismo resample *b* (*b=i*) siempre reciba la misma semilla hija, sin importar cuantos procesos p se usen o cómo *joblib* reparta las tareas entre ellos
  - Esto es la base que permite comparar tiempos de ejecución para sitinto *p* sin que el valor del resultado cambie
- **= numero de hilos internos**: Como el producto de X con su transpuesta se calcula con BLAS y este puede llegar a usar múltiples hilos, la suma de los productos internos puede hacerse en distintos orden según esos distintos hilos, afectando el resultado, por ello para lograr una reproductibilidad más exacta conviene usar el mismo número de hilos internos
- **= versión de las librerías**: como la implementación depende mucho del funcionamiento de las librerías (Numpy, Sklearn, ...), variaciones de versiones en estas pueden generar algoritmos ligeramente distintos, lo que puede generar cierta variabilidad aunque sea menor en los resultados, por ello conviene usar = version para lograr una buena reproductibilidad
- **= dtype**: La cossa cambia si uno usa puntos flotantes de tipo *float32* que *float64*, por ello para fomentar la reproducibilidad, conviene usar = tipo de dato
- **no reusar estado entre versiones/subprocesos**: así evitando que el pool del backend utilizado pueda contaminar la siguiente medición, por

eso `bench.py`hace que cada subproceso sea una nueva versión. Esto más que nada respecto a reproducibilidad temporal que resultados

d) Backend de multiprocessing de joblib

i) El backend de **multiprocessing** utiliza por defecto **loky** (además se setea **loky** a lo largo de la tarea) y gestiona la creación de los **p** procesos hijo. Para la creación de procesos normalmente se usa **fork** en Linux y **spawn** en macOS y Windows - **fork:** aquí el SO clona el proceso padre, creando un proceso hijo que tiene una copia ideńtica del espacio de direcciones y la tabla de paǵinas de la memoria virtual del padre - **spawn:** inicia un ejecutable de Python desde 0, completamente limpio: nuevo interprete, reimporta módulos y reconstruye el contexto de ejecución pasando los argumentos vía serialización

En cuanto a la asignación de memoria, **fork** intenta utilizar **Copy on Write (CoW)**, evitando asignar nueva memoria RAM física, por ende duplicando los datos del programa, sino que hace que el proceso hijo comparta las mismas páginas físicas de la RAM que su padre bajo solo permisos de lectura. Así, solo cuando el padre o el hijo intenten escribir en esa página, el sistema hage un **page fault**, duplicando esa página específica y le asigna memoria RAM física dedicada al hijo. Pero, existe el gran problema que el Garbage Collector y el contador de referencias modifican los encabezados (contadores de referencia) de los objetos en memoria constantemente, incluso para operaciones de lectura, lo que rompe la optimización del **COW**, forzando al SO a duplicar las páginas de RAM innecesariamente. - Si se utilizara **spawn**, se asigna un bloque de RAM independiente desde el inicio, por lo que eso no pasa

ii) En cuanto al manejo de **X** e **y** en *Joblib*, para arreglos grandes de NumPy (umbral de 1 MB aprox) *joblib* usa **Memory Mapping (memmap)**, almacenando termporalmente los arreglos en una RAM compartida (/dev/shm) antes de lanzar las tareas paralelas, entregando solo punteros de lectura mapeados en memoria a cada uno de los **p** procesos (no copias de los datos). Así los procesos leen directamente de los bloques de la matriz original de la RAM, generando un acceso concurrente sin duplicación.

Esto se hace para evitar caer en usar los pipes estandar de **multiprocessing**, en los cuales se tendría que aplicar **pickling (serialización)** a los arreglos y transmitirlos mediante los canales (sockets/pipes) de IPC (comunicación entre procesos) a cada uno de los **p** procesos, lo cual generaría un consumo masivo de memoria al duplicar **p** veces los arreglos en la RAM, además de añadir la penalización temporal relacionada a la serialización

e) Inspección de threads

i) Se corrió el siguiente código en PC-3 (ver specs en inciso f). Primero con el numero exacto de cores físicos:

```
python bs_numpy.py -p 8
============================
[bs_numpy] p=8 B=48 hilos_internos=1 dtype=float64
  tiempo bootstrap :    1.949 s
  hilos totales    : 8 (nucleos fisicos: 8) tasa uso : 1.0
  ancho IC medio   : 0.011812
  cobertura beta*  : 0.950
  ||mean(b)-bhat|| : 4.29e-04
```

Luego, con el numero exacto de cores lógicos:

```
python bs_numpy.py -p 16
============================
[bs_numpy] p=16 B=48 hilos_internos=1 dtype=float64
  tiempo bootstrap :    2.476 s
  hilos totales    : 16 (nucleos fisicos: 8) tasa uso : 2.0
  ancho IC medio   : 0.011812
  cobertura beta*  : 0.950
  ||mean(b)-bhat|| : 4.29e-04
```

Y finalmente con un número mayor al de cores lógicos:

```
python bs_numpy.py -p 32
============================
[bs_numpy] p=32 B=48 hilos_internos=1 dtype=float64
  tiempo bootstrap :    2.672 s
  hilos totales    : 32 (nucleos fisicos: 8) tasa uso : 4.0
  ancho IC medio   : 0.011812
  cobertura beta*  : 0.950
  ||mean(b)-bhat|| : 4.29e-04
```

Notamos que luego de sobrepasar el numero de cores físicos el tiempo de bootstrap toma más tiempo, lo que es un síntoma de la sobresubscripción.

ii) Notamos que en el código el problema ocurre dado que no se limita el numero máximo de workers según los cores físicos. Por lo que se puede prevenir este problema al agregar un techo tal que:

$$p <= cores_fisicos$$

f) Cores lógicos de computador

Métrica	PC-1 (sebas)	PC-2 (kintsugi)	PC-3 (aurora-ferrum)
Cores lógicos	8	8	16
Cores físicos	4	4	8

Resultados PC-1

p	bs_auto	bs_numpy	bs_sklearn
1	73.493	6.431	42.273
2	71.334	4.848	41.773
3	62.907	4.994	37.568
4	61.056	4.568	38.712

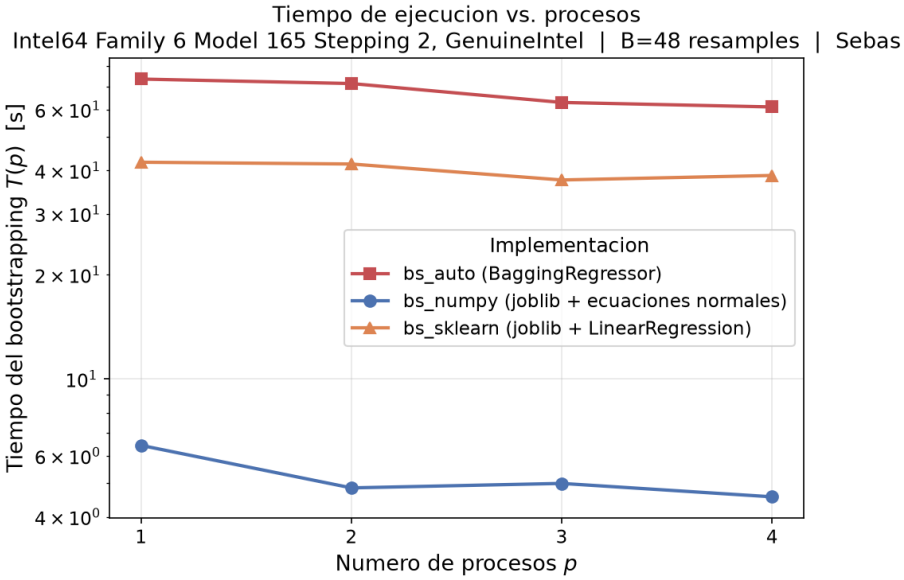


Figure 1: Gráfico tiempo vs. p

Resultados PC-2

p	bs_auto	bs_numpy	bs_sklearn
1	118.865	17.831	80.963
2	94.721	13.185	67.087
3	97.95	8.361	57.659
4	97.677	9.716	62.858

Resultados PC-3

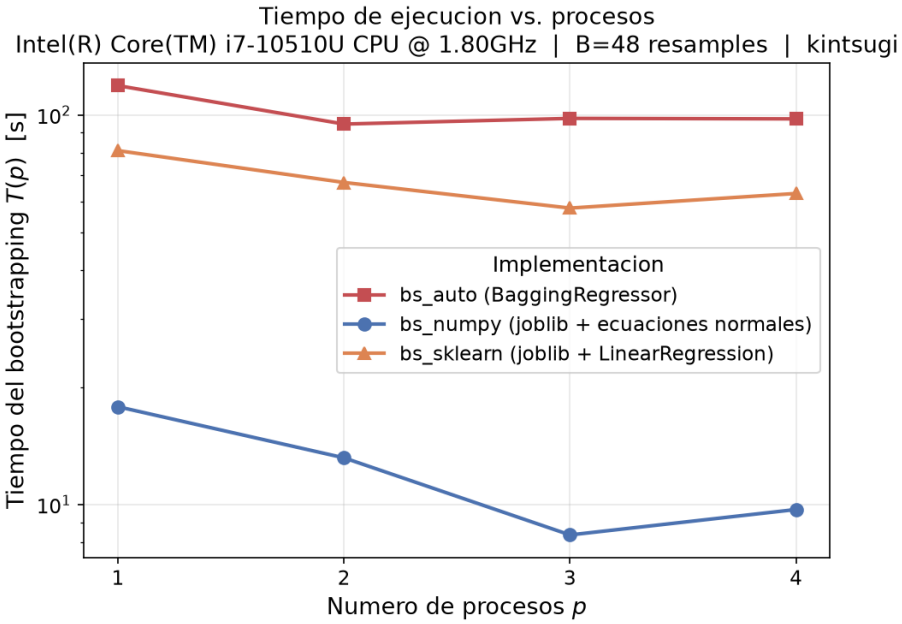


Figure 2: Gráfico tiempo vs. p

p	bs_auto	bs_numpy	bs_sklearn
1	52.009	3.467	32.474
2	36.338	2.382	19.52
3	35.3	2.001	16.216
4	31.354	1.86	15.214
5	31.247	1.798	16.734
6	31.287	1.781	16.841
7	31.742	1.824	17.509
8	31.904	1.876	18.05

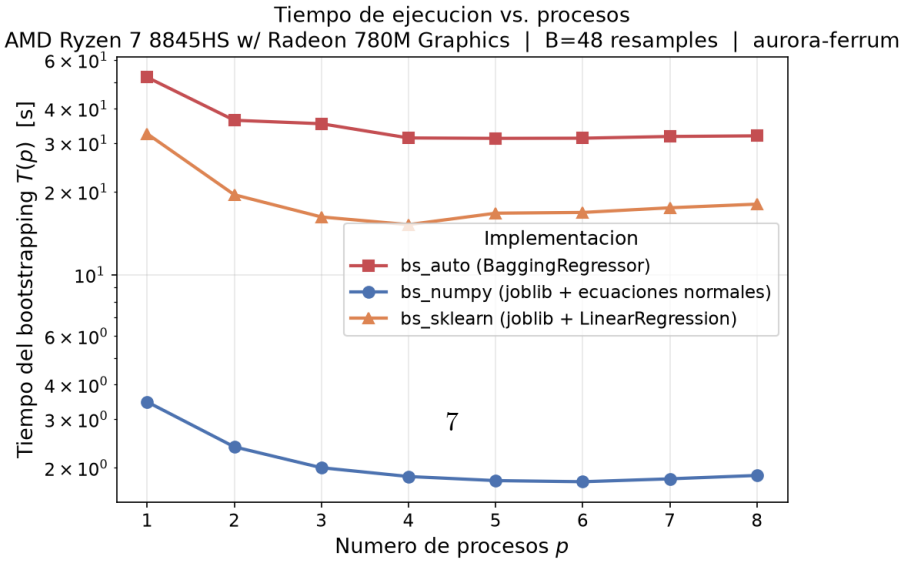
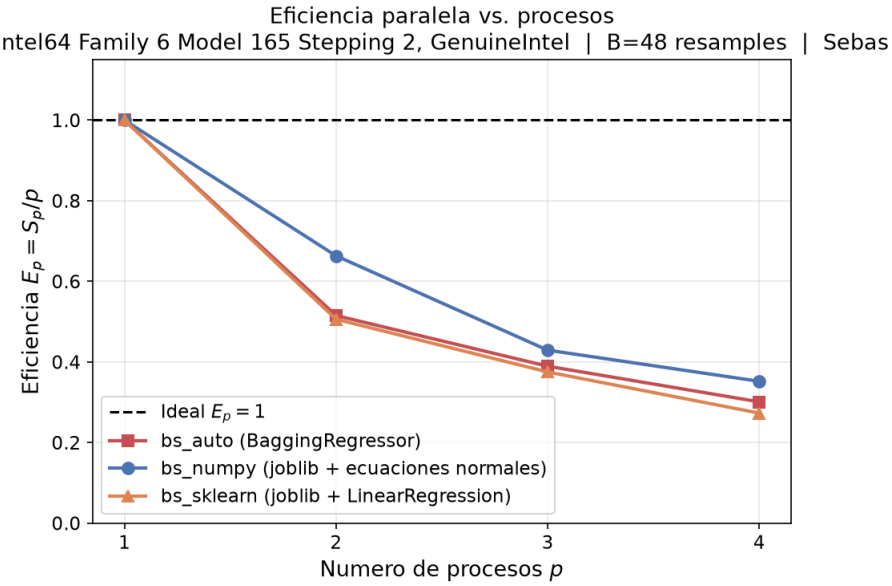
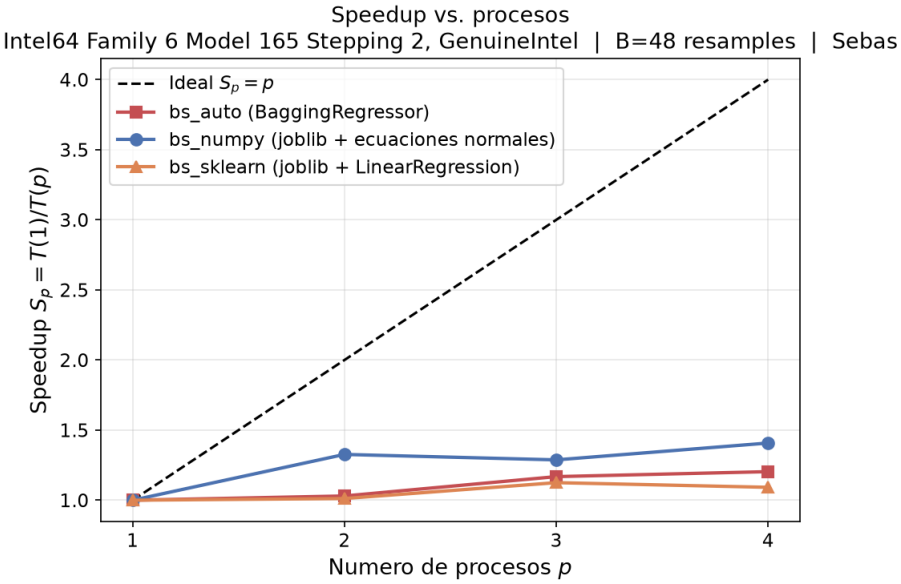


Figure 3: Gráfico tiempo vs. p

g) T(p), S(p), E(p)



PC-1



bs_auto

p	T(p) [s]	S(p)	E(p)
1	73.493	1.000	100.0%

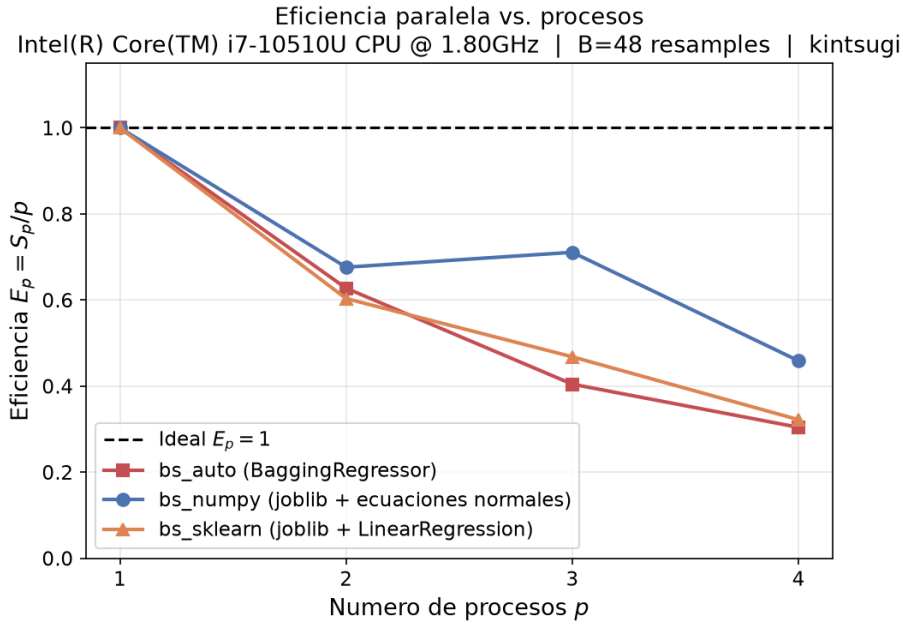
p	T(p) [s]	S(p)	E(p)
2	71.334	1.030	51.5%
3	62.907	1.168	38.9%
4	61.056	1.204	30.1%

bs_numpy

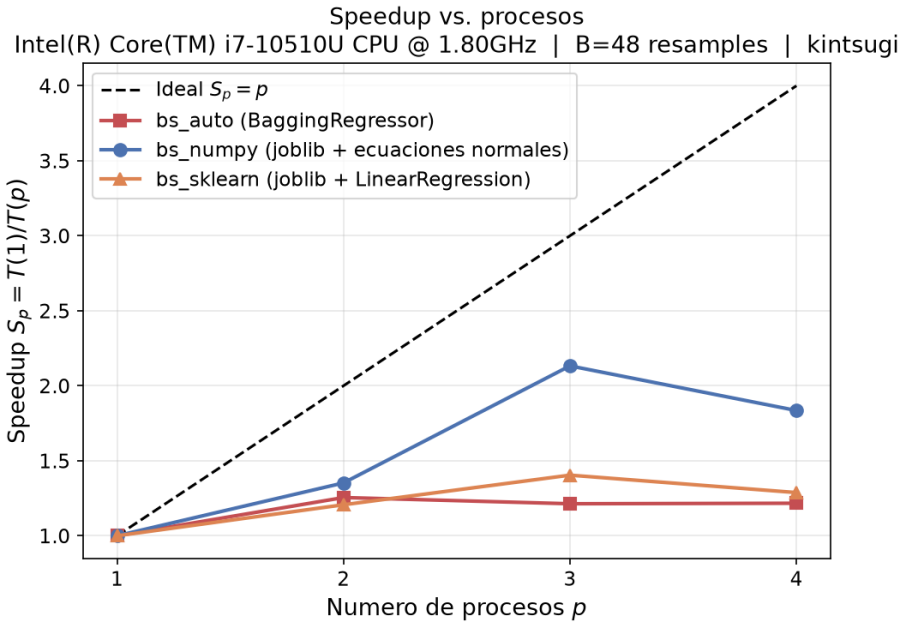
p	T(p) [s]	S(p)	E(p)
1	6.431	1.000	100.0%
2	4.848	1.327	66.3%
3	4.994	1.288	42.9%
4	4.568	1.408	35.2%

bs_sklearn

p	T(p) [s]	S(p)	E(p)
1	42.273	1.000	100.0%
2	41.773	1.012	50.6%
3	37.568	1.125	37.5%
4	38.712	1.092	27.3%


Eficiencia paralela vs. procesos
Intel(R) Core(TM) i7-10510U CPU @ 1.80GHz | B=48 resamples | kintsugi
Eficiencia $E_p = S_p/p$
Numero de procesos p
Ideal $E_p = 1$
bs_auto (BaggingRegressor)
bs_numpy (joblib + ecuaciones normales)
bs_sklearn (joblib + LinearRegression)
0.0
0.2
0.4
0.6
0.8
1.0
1
2
3
4

PC-2


Speedup vs. procesos
Intel(R) Core(TM) i7-10510U CPU @ 1.80GHz | B=48 resamples | kintsugi
Speedup $S_p = T(1)/T(p)$
Numero de procesos p
Ideal $S_p = p$
bs_auto (BaggingRegressor)
bs_numpy (joblib + ecuaciones normales)
bs_sklearn (joblib + LinearRegression)
1.0
1.5
2.0
2.5
3.0
3.5
4.0
1
2
3
4

bs_auto

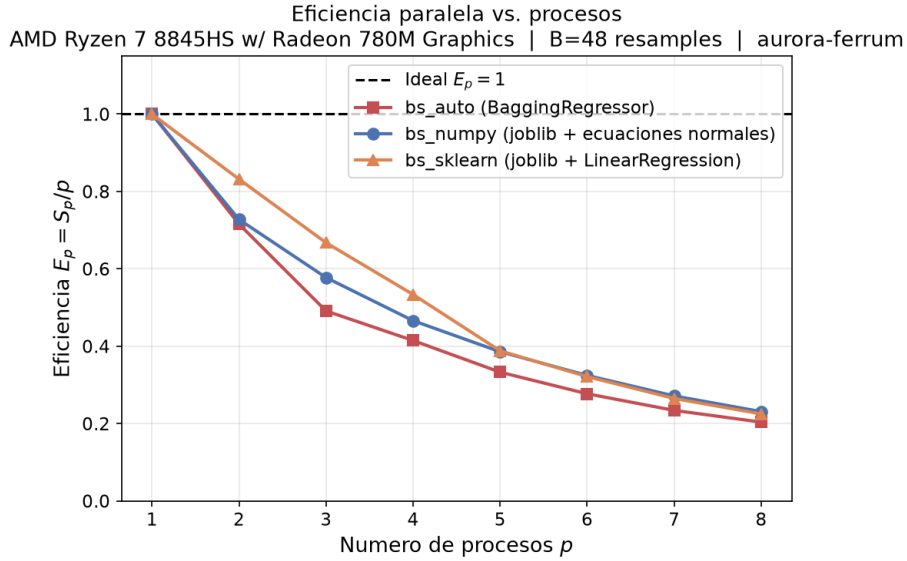
p	T(p) [s]	S(p)	E(p)
1	118.865	1.000	100.0%
2	94.721	1.255	62.7%
3	97.950	1.214	40.5%
4	97.677	1.217	30.4%

bs_numpy

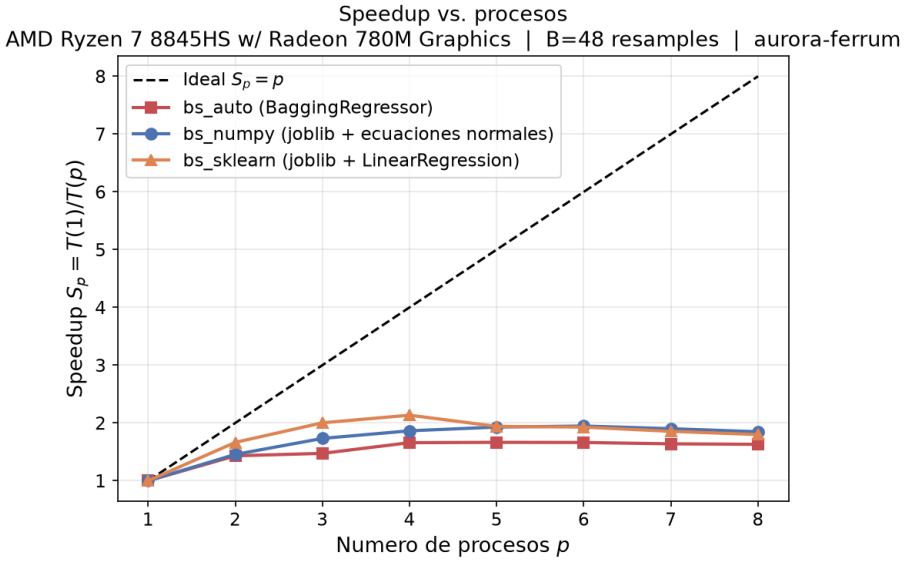
p	T(p) [s]	S(p)	E(p)
1	17.831	1.000	100.0%
2	13.185	1.352	67.6%
3	8.361	2.133	71.1%
4	9.716	1.835	45.9%

bs_sklearn

p	T(p) [s]	S(p)	E(p)
1	80.963	1.000	100.0%
2	67.087	1.207	60.3%
3	57.659	1.404	46.8%
4	62.858	1.288	32.2%



PC-3



bs_auto

p	T(p) [s]	S(p)	E(p)
1	52.009	1.000	100.0%
2	36.338	1.431	71.6%
3	35.300	1.473	49.1%
4	31.354	1.659	41.5%

p	T(p) [s]	S(p)	E(p)
5	31.247	1.664	33.3%
6	31.287	1.662	27.7%
7	31.742	1.638	23.4%
8	31.904	1.630	20.4%

bs_numpy

p	T(p) [s]	S(p)	E(p)
1	3.467	1.000	100.0%
2	2.382	1.455	72.8%
3	2.001	1.733	57.8%
4	1.860	1.864	46.6%
5	1.798	1.928	38.6%
6	1.781	1.947	32.4%
7	1.824	1.901	27.2%
8	1.876	1.848	23.1%

bs_sklearn

p	T(p) [s]	S(p)	E(p)
1	32.474	1.000	100.0%
2	19.520	1.664	83.2%
3	16.216	2.003	66.8%
4	15.214	2.134	53.4%
5	16.734	1.941	38.8%
6	16.841	1.928	32.1%
7	17.509	1.855	26.5%
8	18.050	1.799	22.5%

Comentarios: Se utilizó T(1) como el tiempo con un sólo worker para par cada implementación en cada computador de forma que sea más fácil comparar la pérdida de eficiencia.

h) Overhead según p

PC-1

bs_auto (T1 = 73.493 s)

p	T(p) [s]	T0(p) [s]
1	73.493	0.000
2	71.334	69.175
3	62.907	115.228
4	61.056	170.731

bs_numpy (T1 = 6.431 s)

p	T(p) [s]	T0(p) [s]
1	6.431	0.000
2	4.848	3.265
3	4.994	8.551
4	4.568	11.841

bs_sklearn (T1 = 42.273 s)

p	T(p) [s]	T0(p) [s]
1	42.273	0.000
2	41.773	41.273
3	37.568	70.431
4	38.712	112.575

PC-2

bs_auto (T1 = 118.865 s)

p	T(p) [s]	T0(p) [s]
1	118.865	0.000
2	94.721	70.577
3	97.950	174.985
4	97.677	271.843

bs_numpy (T1 = 17.831 s)

p	T(p) [s]	T0(p) [s]
1	17.831	0.000
2	13.185	8.539
3	8.361	7.252

p	T(p) [s]	T0(p) [s]
4	9.716	21.033

bs_sklearn (T1 = 80.963 s)

p	T(p) [s]	T0(p) [s]
1	80.963	0.000
2	67.087	53.211
3	57.659	92.014
4	62.858	170.469

PC-3

bs_auto (T1 = 52.009 s)

p	T(p) [s]	T0(p) [s]
1	52.009	0.000
2	36.338	20.667
3	35.300	53.891
4	31.354	73.407
5	31.247	104.226
6	31.287	135.713
7	31.742	170.185
8	31.904	203.223

bs_numpy (T1 = 3.467 s)

p	T(p) [s]	T0(p) [s]
1	3.467	0.000
2	2.382	1.297
3	2.001	2.536
4	1.860	3.973
5	1.798	5.523
6	1.781	7.219
7	1.824	9.301
8	1.876	11.541

bs_sklearn (T1 = 32.474 s)

p	T(p) [s]	T0(p) [s]
1	32.474	0.000
2	19.520	6.566
3	16.216	16.174
4	15.214	28.382
5	16.734	51.196
6	16.841	68.572
7	17.509	90.089
8	18.050	111.926

Comentarios: Notamos que existe un overhead que creciente con el número de procesos. Que se correlaciona con el costo de realizar un fork y copiar los datos del proceso dado que estos no comparten memoria a diferencia de los threads.

i) Versión más eficiente

Notamos que la versión más eficiente fue por lejos la implementación de numpy. Como se vió en los datos expuestos anteriormente, el desempeño fue el mejor en los 3 equipos probados. Obteniendo el menor tiempo, y mayor retención de eficiencia y speedup a medida que se agregan workers.

PC-3 (aurora-ferrum, p_max=8)

p	t (inner threads)	tiempo bootstrap [s]	ancho IC medio	cobertura beta*	||mean(b)-bhat||
1	1	5.348	0.011812	0.950	4.29e-04
1	2	4.281	0.011812	0.950	4.29e-04
1	3	4.082	0.011812	0.950	4.29e-04
1	4	4.440	0.011812	0.950	4.29e-04
1	5	5.908	0.011812	0.950	4.29e-04
1	6	3.895	0.011812	0.950	4.29e-04
1	7	5.978	0.011812	0.950	4.29e-04
1	8	6.485	0.011812	0.950	4.29e-04
2	1	3.486	0.011812	0.950	4.29e-04
2	2	3.041	0.011812	0.950	4.29e-04
2	3	2.895	0.011812	0.950	4.29e-04
2	4	3.044	0.011812	0.950	4.29e-04
3	1	2.355	0.011812	0.950	4.29e-04
3	2	2.260	0.011812	0.950	4.29e-04
4	1	2.657	0.011812	0.950	4.29e-04
4	2	3.013	0.011812	0.950	4.29e-04
5	1	2.534	0.011812	0.950	4.29e-04
6	1	2.350	0.011812	0.950	4.29e-04

p	t (inner threads)	tiempo bootstrap [s]	ancho IC medio	cobertura beta*	||mean(b)-bhat||
7	1	2.361	0.011812	0.950	4.29e-04
8	1	2.158	0.011812	0.950	4.29e-04

PC-1 (sebas, p_max=4)

p	t (inner threads)	tiempo bootstrap [s]	ancho IC medio	cobertura beta*	||mean(b)-bhat||
1	1	11.195	0.011812	0.950	4.29e-04
1	2	8.553	0.011812	0.950	4.29e-04
1	3	16.773	0.011812	0.950	4.29e-04
1	4	15.453	0.011812	0.950	4.29e-04
2	1	6.443	0.011812	0.950	4.29e-04
2	2	6.368	0.011812	0.950	4.29e-04
3	1	5.476	0.011812	0.950	4.29e-04
4	1	5.361	0.011812	0.950	4.29e-04

j) Comparación de resultados

Notamos que los mejores resultados se alcanzaron con un único thread, con un numero de procesos igual al número de nucleos físicos de cada máquina. Cabe mencionar también que incluso bajo los mismos valores de p,t. PC-3 tuvo un mejor desempeño. Probablemente debido a la diferencia de frecuenica de los procesadores, haciendo la ejecución de PC-3 más rápida. Esto resalta la importancia de comparar cada máquina por separado, dado que estas diferencias de performance influyen tanto en el tiempo de ejecución mínimo, como también determinan la combinación óptima de threads/procesos en cada caso.

Uso de IA:

Se utilizó IA para: - Buscar posibles optimizaciones al código implementado iterativamente (Claude) - Debuggear errores de código (Claude) - Explicar detalles de implementación de las libererías que impactaban en el código y sus resultados (Claude) - Generar un script de bash que pruebe todas las combinaciones relevantes de p,t dado un valor de p_max (Claude) - Generar tablas de markdown a partir de logs de ejecución (ChatGPT)